

基于数据驱动的 MBTI 人格测试

Python 应用开发基础课程报告

小组成员：李京霖，孙翊宸，徐瑕

任课教师：雷杰

报告时间：2022/12/30

摘要：MBTI 人格测试，可以在一定程度上反应人的性格特征。在本项目中，我们利用机器学习来进行对发帖人的 MBTI 人格分析，来预测发布者的 MBTI 人格。在项目实际操作中，我们使用多种机器学习模型来对数据进行训练，从中找到最合适的机器学习模型，并对合适的机器学习模型进行优化。

关键词：机器学习，爬虫，数据分析

目录

1. 项目概要.....	1
1.1 项目背景	1
1.2 项目介绍	1
2. 数据模块.....	2
2.1 数据收集	2
2.2 数据处理	2
2.3 数据分析	3
2.3.1 MBTI 16 种人格发帖分析.....	3
2.3.2 MBTI 16 种人格词云分析.....	4
2.3.3 MBTI 四种特征关联程度分析	5
2.4 特征提取	7
3. 机器学习模型	7
3.1 模型训练	7
3.2 成果展示	9
4. 特色.....	9
5. 任务分工.....	10
6. 分析总结.....	10

1.项目概要

1.1 项目背景

MBTI 人格测试全称叫做十六型人格分析测试，因为广泛运用于职业测评，所以也叫职业性格测试。MBTI 由四个维度，八个方面组成。经近 70 多年的实践和发展，MBTI 已成为世界范围通用的性格测试，被广泛运用于自我了解与发展、职业规划、专业选择、团队建设管理和领导培训、解决问题、人际关系辅导、教育及课程开发、多元化和多元化的培训等诸多领域。

在微博上对于一些比较喜欢使用 MBTI 人格的人来说，在网络冲浪时转发符合自己描述的文字、梗图，或是寻找同类型人格，具有十足乐趣。然而，当某人的帖子中不包含 MBTI 关键词时，那么如何根据某人发布的帖子，来判断他的 MBTI 人格类型，则是难点。

为此，我们提出基于数据驱动的 MBTI 人格测试方法，以达到快速判断对方的 MBTI 人格的目的。

1.2 项目介绍

在本项目中，我们首先利用爬虫从网络上收集微博超话数据，对数据进行筛选，删除掉一些不合标准的数据，将余下的数据制作成数据集。

再通过多种机器学习模型和不同的数据特征提取方式对数据进行测试，以期找到最切合数据的学习模型与数据特征提取。在不同的机器学习模型中，找到准确率最高的机器学习模型对数据进行训练。

在应用方面，利用训练好的机器学习模型，通过从某个人发布的帖子进行预测，判断此人的 MBTI 人格类型。

2. 数据模块

2.1 数据收集

我们通过爬虫从微博超话获取 MBTI 人格相关数据，数据总量超过 2W+。

爬虫具体操作：

- 利用 requests 库请求网站；
- Selenium 直接抓取网页渲染源码；
- 再通过 re 正则表达式和 setAttribute 提取包含 MBTI 人格的数据；
- 存储 MBTI 人格数据。




图 2-1 最终获得的 MBTI 人格数据

2.2 数据处理

数据处理主要有两部分。一是：对数据进行清洗，删除不满足条件的数据；

数据中不应包含：

1. 空值及重复值；
2. 数据内容中，出现多种的 MBTI 人格类型；
3. 数据内容少于 10 个字数或过长；
4. 数据是机器人投稿的帖子；
5. 数据中包含 MBTI 关键词；
6. 数据中的链接。

```
# 删除空数据
def drop_null(df):
    df = df.dropna(axis=0, how='any')
    return df

data = drop_null(data)
```

图 2-2-1 删除空数据

二是：将标签转换为数字。

MBTI	content	IE	NS	TF	JP
0 ENFJ	投喂和超强免疫力！想问问是怎么忍受孤独的呢，其实很想学会自己一个人，因为有时候会觉得社交很累...	0	1	0	1
1 ENFJ	！投喂炸番茄和土豆泥！笨人intp，表白朋友+小说搭子（她enfj），们俩真的很合得来！看小...	0	1	0	1
2 ENFJ	！打扰力，想问问ENFJ面对喜欢的人会有什么样的表现——？心选是ENFJ，然后本人是非常没自...	0	1	0	1
3 ENFJ	boy，想问问ENFJ的是什么职业，做得开心吗？笨人做新药研发已经快抑郁了...同事之间基本...	0	1	0	1
5 ENFJ	！投喂一盒利来在别的那边看到有问性取向的，遂奇enfj里无性恋多不多不会就一个吧...	0	1	0	1

图 2-2-2 将标签转换为数字

2.3 数据分析

2.3.1 MBTI 16 种人格发帖分析

数据中，与其他人格对比 INFP、INFJ、INTP、INTJ 等人格发帖总数更多且发帖总字数更是远超于其人格。




图 2-3-1 最终获得的 MBTI 人格数据




图 2-3-2 每条发帖的字数

2.3.2 MBTI 16 种人格词云分析

通过词云分析，可以看到不同性格的人，发布的帖子关键词有所不同。而我们的模型分为两部分：一部分是针对英文帖子的训练，另一部分是对中文帖子的训练。



图 2-3-3 帖子中出现最多的英文词云




图 2-3-4 帖子中出现的中文词云

2.3.3 MBTI 四种特征关联程度分析

由热图可知，IE，NS，TF，JP 四种特征相关系数较低。所以可以使用这四种特征来训练模型。




图 2-3-5 中文帖子的热图




图 2-3-6 英文帖子的热图

2.4 特征提取

我们最开始采用的是将所有 16 种性格作为独特的特征，用于特征工程的 Tf-idf 评估一个词与文档网或语料库集合中的文档的相关/重要程度。当我们在这里训练单个分类器时，它会起到作用。对于我们的模型，我们使用 count vectorizer 和 tf-idf vectorizer 进行矢量化，使单词出现在帖子的 10% 到 70% 之间。

但实际运行过程中，发现模型的模型准确率较低，因此我们更换特征，单独训练 4 个分类器根据 MBTI 类型对他们的性格进行分类。从运行结果上看，单独使用 4 个分类器来对模型进行训练的效果比使用 16 种性格作为独特的特征的效果更好。

3. 机器学习模型

3.1 模型训练

在模型训练上，我们采用多个模型同时训练，以期望从中找到最合适的机器学习模型，来进行预测。

在实际执行过程中，我们先实现了以英文帖子为数据的模型训练。我们最先采用了所有 16 种性格作为独特的特征以及数据集的划分比例为 60：40，各模型准确率如下：

Accuracies(%)	
Random Forest	39.533510
XG Boost	57.868320
Gradient Descent	37.348686
Logistic Regression	58.134042
KNN	16.445232
SVM	35.518158


从各模型准确率中看出，当我们在数据集上应用 60:40 的拆分比时，该模型对数据集的拟合不足，且最高的模型准确率不超过 60%，准确率比较低。

因此我们使用划分比例为 70：30 的数据集划分，借此优化模型训练，但实际训练过

程中，一部分模型训练的准确率上升，但模型训练后的准确率仍然较低，


Accuracies(%)	
Random Forest	37.866858
XG Boost	57.122405
Gradient Descent	39.047960
Logistic Regression	57.122405
KNN	16.964925
SVM	35.755190

上述 ML 分类器的执行效率仅为近 50%。因此，我们最终没有选择所有 16 种性格作为独特的特征，而是单独训练 4 个分类器根据 MBTI 类型对他们的性格进行分类。



选取 IE、NS、TF、JP 四种特征作为分类器，可以看见总体的模型准确率都有所上升，其中以 XGBoost 机器学习模型的平均准确率最高。

最后我们采用以 IE、NS、TF、JP 四种特征作为分类器和 XGBoost 机器学习模型来训练英文数据。在后续的优化过程中，我们继续以 IE、NS、TF、JP 四种特征作为分类器，来训练中文数据。在实践过程中，中文数据的拟合度比英文数据要低一些。



所以我们中文数据与英文数据使用的是不同的机器学习模型来进行训练。

3.2 成果展示

当输入需要预测对象发布的帖子后，机器学习模型将会给出预测的结果。

```
my_posts = """ 我今年 21 岁了，目前正在攻读计算机科学与技术研究生学位，这个双学位读出来要五年，我目前的 CGPA 是 3.8/4.0。
我从小就对教学充满热情。数学一直是我在学校感兴趣的科目。此外，我的母亲一直是我最大的灵感来源之一。
她的职业生涯始于教师，现在她在农村和城市地区的学前学校拥有自己的教育信托。
在封锁期间，我专注于 Instagram 上的博客和内容创作领域。传播爱的积极善意。
我希望我能够为平台提供最好的服务，我乐观的态度有助于实现预期的增长。谢谢你给我的机会。 """
```

该模型的预测结果为：

结果 INFP

而使用的 XGBoost 机器学习模型的预测准确率为：

IE: Introversion (I) / Extroversion (E) Accuracy: 77.37%
 NS: Intuition (N) / Sensing (S) Accuracy: 85.85%
 FT: Feeling (F) / Thinking (T) Accuracy: 70.28%
 JP: Judging (J) / Perceiving (P) Accuracy: 64.37%

4. 特色

1. 使用多种机器学习模型对数据进行测试，找到最适合的数据模型；
2. 使用标签编码而不是单热编码，可以减少预处理时间；

3. 使用爬虫获取含有 MBTI 相关数据；
4. 充分应用课程知识，串联各章节重点进行数据分析处理；

5.任务分工

1. 李京霖（组长）：数据收集处理
2. 孙翊宸：机器学习模型与结果预测
3. 徐瑕：报告撰写主笔，ppt

6.分析总结

通过此次课程设计，我们能够将课堂知识与实际结合起来，并在此基础上探索一些新的应用形式。我们结合数据处理、数据分析和机器学习，可以初步分析我们在日常生活中遇到的一些问题，并且可以利用学到的课堂知识来实际应用。该课程的目的已初步实现。

但除此之外，我们也还有许多的不足，例如对问题的应变能力还有待提升。在我们的程序中也有很多值得改进的地方。

在算法设计的过程中，我们在开始时，希望可以从多种机器学习模型中找到最适合我们项目的机器学习模型，在实际开发的过程中，发现预测时机器学习准确率仍有待提高。后续我们也对项目设计进行了优化，由只能对发布的英文帖子进行预测，更新到可根据中文帖子预测发帖者的 MBTI 人格。