

基于数据驱动的下零售店消费者画像建模方法

Python 应用开发课程报告

徐声远、叶飞、杨铁皓

1 概要

为促进卷烟新零售加速转型，利用大数据技术提高卷烟销量，本文基于收集的消费者历史购买记录，提出了基于数据驱动的烟草客户画像建模方法。所做的工作主要为如下四个方面：1、使用数据库技术对杂乱的几百万条数据进行了数据清洗。2、用 `pandas` 实现了传统 RFM 模型，并设计了增量式 RFM 模型对历史消费者进行价值分类，支持模型动态更新，比传统 RFM 模型更新速度更快；3.利用 TGI 模型分析了不同类别客户的卷烟偏好，从而指导零售终端优化营销策略；4.使用支持向量机、决策树、随机森林等机器学习模型对用户下次购买商品进行预测并达到了。

2 问题描述

随着电子商务的普及，许多线下零售店受到前所未有的冲击，它们的。但是随着近几年线下零售店转型升级，智能销售终端开始普及，使得线下零售店能够收集到消费者的历史购买记录。通过合理利用这些消费者数据，可以有效帮助下零售店合理配置资源，提高消费者黏性，但是如何通过对消费者的购买行为记录进行分析，形成对消费者的消费动机、消费能力、消费偏好、消费习惯和消费趋势的精准认识是目前的主要难点。为此，本文提出基于数据驱动的烟草客户画像建模方法，主要包含对客户的粗粒度价值分类和偏好分析，以及细粒度的购买行为预测。

本文基于智能消费终端收集到的用户购买行为，首先采用 RFM 模型对客户进行价值评估，根据用户最近一次消费、消费频率以及消费金额三个指标判断客户对公司的价值。基于由帕累托提出的 80/20 法则，即在顶部的 20% 客户创建了公司 80% 的利益，可以建议公司重点服务忠诚度高的老客户，而对忠诚度不高的用户则采用挽留的推新策略。本文还对 RFM 模型进行了增量式优化，随着新的用户购买行为数据不断产生，设计了高效的更新策略，避免重复读取历史数据，造成不必要的冗余计算，从而加快了 RFM 模型更新效率。同时本文引入 TGI (Target Group Index) 模型，根据用户的消费记录分析用户的消费习惯，对用户根据其所属类型进行一定程度的偏好刻画，有利于按人群推荐其偏好的产品。另外，为了帮助零售终端实现细粒度的卷烟精准营销，测试了支持向量机、决策树、随机森林等机器学习模型的购买产品预测准确程度。模型将用户最近 5 次的购买的卷烟以及历史上购买最频繁的卷烟作为模型输入，最终预测未来该用户最可能购买的卷烟品牌。

本文主要贡献如下：

- (1) 提出一种增量式 RFM 模型更新方法，能够随着数据不断累积快速更新旧的 RFM 模型。
- (2) 利用 TGI 模型对 RFM 分类的客户进行了卷烟偏好分析。

(3) 使用了机器学习算法预测了未来该用户最可能购买的卷烟品牌。

3 数据来源/预处理

数据来源于湖北烟草局近两年的后台消费记录，数据量大小是百万级，存储在 `mysql` 数据库中。

本小节，我们将利用湖北省某地级市 2019/06/09 至 2021/03/09 期间卷烟销售终端收集的真实用户消费记录进行实验验证。通过数据清洗和预处理，最终获得的数据包含 371089 个用户，519095 条购买记录，其中共有 1655 种卷烟品牌。

以下是初始数据一览，包含五个表，每个表的数据量，字段名以及一条数据的样式。数据量大，格式不统一；这两个难点给我们的数据清洗工作带来了极大的困扰。

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W		
1	由于数据保密性原因，下列示例代码只在形式上与原数据库一致，内容方面全部经过修改																								
2																									
3	unit_goods 共20982条数据																								
4	ID	CREATED BY	CREATED	LAST MC	LAST MC	APPROV	BIG ICON	CODE	IS HOT	NAME	PRODUCE	PROMOT	REMARK	RETAIL	SMALL K	SOLD TC	STATUS	SYSTEM	UNIT	TOBACCO					
5	"111111111"	yc	"24/4/2020"	yc	"28/8/2020"	11		"48915993"	0	王老吉凉茶310ml*12罐*2				"35"	"Goods/YC"	0	0	YC	瓶	0					
6																									
7	unit_order 共条457027条数据																								
8	ID	CREATED BY	CREATED	LAST MC	LAST MC	ACCOUNT	ACCOUNT	ADDRESS	CHANNEL	CITY	COMMISSION	COMMISSION	COMMISSION	DISTRIB	EXPECT	FINISHED	GIVE BY	GIVE DA	GIVED	LADING	LADING	MCH ID	ORDER ID		
9	"100000000"	pay	"9/8/2019"	"point give"	"9/8/2019 18:41:42"			weixin			0	0	0	0	0	point	"15653473"	1	0			"42100200"	"15653471"		
10																									
11	unit_order_item 共条567362条数据																								
12	ID	CREATED BY	CREATED	LAST MC	LAST MC	AMOUNT	COMMISSION	DEBATE	GOODS	GOODS	GOODS	POINT	POINTS	PRICE	QUANTIT	REMARK	UNIT	ORDER ID	TOBACCO	COST PRICE					
13	"100000000"	pay	"9/8/2019 18:39:22"			"18"	0	0	0		"69300441"	良品	0	0	18	1	盒	"10000878"	0						
14																									
15	payment 共有4422093条数据																								
16	ID	ACQ SERIAL	AMOUNT	BOX ID	CARNO	CHANNEL	CREATED	GOODS	GOODS	ISS BANI	ISS CHA	ISS MCH	ISS SERI	MCH ID	ORDER ID	ORG ACI	ORG ORI	PARK ID	PAY APP	PAY ID	PAY TYP	PAYER	QRC SER		
17	"00001F4F"	"18CEC675C5"	"145"	"DA0419B640000"	0000	"16080180"	"unitPrice":145,"s"	"OTHERS":WX						"13012020"	"42100200"	"18CEC675C5C24A1"	"20201215"	"25982718886020000"		grspay		o-Nxa8IC	1bd1f82039f		
18	<bank type><[[CDATA[OTHERS]]]><bank type>																								
19	<cash_fee><[[CDATA[14500]]]><cash_fee>																								
20	<charset><[[CDATA[UTF-8]]]><charset>																								
21	<coupon_fee><[[CDATA[0]]]><coupon_fee>																								
22																									
23	yc_store 共有229条数据																								
24	yc_store ID	CREATED	CREATED	LAST MC	LAST MC	GEODEFA	GEOLOGA	MCH ID	NAME	POINT	STATUS	TELNO	SHORT NAME												
25	"21279931"	mfm	"14/4/2020 18:30:47"			"0"	"0"	"4210020000"	0	0	0														

图 1 初始数据一览

我们的数据处理全部用 `python` 连接数据库实现，大致包含了如下工作：

(1) 进行了字段含义、外键的分析，筛选出了有用的字段，并设置用户 `id` 为索引将他们连接成一个表。

(2) `payment` 表包含 `xml` 格式数据导致数据表格式错乱，多行一条数据，将其修复。

(3) `payment` 表中的一次消费记录可能包含购买多种商品，将其转化为一种商品一条数据。

(4) `payment` 表中的 `GOODS_DETAIL` 字段格式是一个列表，包含了商品单价、购买数量、商品是否为烟草种类等信息，将其拆分为多个字段。

最终结果形如订单号(`ORDER_ID`) :谁 (`ID`) 什么时候 (`CREATED_DATE`) 在哪里 (`STORE_ID`)买了什么(`GOODS_NAME`)商品单价多少(`PRICE`)买了几件(`QUANTITY`)是否属于烟草类 (`TOBACCO`) :

ORDER_ID	CREATED_DATE	STORE_ID	ID	GOODS_DETAIL	PAYER	GOODS_NAME	PRICE	QUANTITY	TOBACCO
"AA175A6188654..."	"26/8/2019 05..."	"71621690..."	"1074625..."	"[{"unitPrice":35,"smalllocn":"","unit":"","quantity":..."	"o8qV_5gK4XMDyV.R..."	"商品"	"35"	"1"	"0"
"C2C6C9361E73..."	"20/8/2019 08..."	"71621690..."	"1048036..."	"[{"unitPrice":12,"smalllocn":"","unit":"","quantity":..."	"o8qV_5gZ9eWnw.R1..."	"商品"	"12"	"1"	"0"
"B4BA09DF5587..."	"20/8/2019 08..."	"71621690..."	"1048002..."	"[{"unitPrice":18,"smalllocn":"","unit":"","quantity":..."	"o8qV_Sh2WkZZvYTR..."	"商品"	"18"	"1"	"0"
"41502AD4CB9E..."	"15/8/2019 03..."	"71621690..."	"1024476..."	"[{"unitPrice":30,"smalllocn":"","unit":"","quantity":..."	"o8qV_Shax_k-R5yGm..."	"商品"	"30"	"1"	"0"
"09490FC4E4FC..."	"20/8/2019 08..."	"71621690..."	"1048023..."	"[{"unitPrice":19,"smalllocn":"","Goods/YC/6901028180580..."	"o8qV_ShKYrmR4a38r..."	"黄鹤楼(软蓝)"	"19"	"1"	"0"
"F4C0592BC2F8..."	"22/8/2019 03..."	"71621690..."	"1056133..."	"[{"unitPrice":150,"smalllocn":"","unit":"","quantity":..."	"o8qV_ShNuHh7zpQS4..."	"商品"	"150"	"1"	"0"

图 2 清理后数据一览

4 模型设计

4.1 RFM 模型

4.1.1 传统 RFM 模型介绍

RFM 模型是一种常用的用于评价客户流失倾向、忠诚度和客户价值的计算方法，这一模型通过客户的最近的购买时间、购买的频率以及消费的价格三项指标来动态地刻画客户，即距离上一次交易的时间 R （简称“近度”，Recency）、最近 N 个月的交易次数 F （简称“频度”，Frequency）和最近 N 个月的交易金额 M （简称“额度”，Monetary）的综合分析。

RFM 模型会计算三个指标的整体平均值，记作 r_{avg} 、 f_{avg} 和 m_{avg} ，然后根据每个客户自身的 RFM 指标与平均值的大小关系，将对应指标标记为 0 或 1，即：

$$sr_i = \begin{cases} 1 & r_i < r_{avg} \\ 0 & r_i \geq r_{avg} \end{cases}$$
$$sf_i = \begin{cases} 1 & f_i > f_{avg} \\ 0 & f_i \leq f_{avg} \end{cases}$$
$$sm_i = \begin{cases} 1 & m_i > m_{avg} \\ 0 & m_i \leq m_{avg} \end{cases}$$

基于上述公式，每个客户都可以被 3 个 0/1 标记，最终可以分类成如表 1 所示的 8 类用户。

表 1 RFM 模型用户分类

用户分类	近度 R	频度 F	额度 M
重要价值用户	1	1	1
重要发展用户	1	0	1
重要保持用户	0	1	1
重要挽留用户	0	0	1
一般价值用户	1	1	0
一般发展用户	1	0	0
一般保持用户	0	1	0
一般挽留用户	0	0	0

4.1.2 增量式 RFM

RFM 模型的三个指标都具有实时性，即消费的近度、频度、额度都会随着时间的流逝、订单的产生进行改变。同时用户的消费习惯、消费需求也并非一成不变，它随时可能因为用户新的尝试、烟酒销售的淡旺季、年龄的成长等因素进行改变，对用户消费习惯的攫取和预测更应该以“近况”为准。因此，为了获得最新的 RFM 模型，需要在历史消费数据的基础上，考虑新产生的消费数据。但是如果使用传统计算方法对历史数据以及新产生的数据重新计算 RFM 模型，将非常耗时，尤其是当历史数据规模非常庞大时。因此，在本节我们提出一种增量式 RFM 计算方法，在历史 RFM 模型基础上，对新产生的消费数据统计相关指标，快速更新 RFM 模型。

对于历史数据，每个用户 i 的 RFM 指标记作： R_i^{old} 、 F_i^{old} 、 M_i^{old} 。对于新增的数据，其

中用户 j 的 RFM 指标记作: R_j^{new} 、 F_j^{new} 、 M_j^{new} 。为了更新旧的 RFM 模型, 需要考虑新增的数据, 此时会出现如下三种情况:

➤ 情况 1: 用户 u 在历史数据和新增数据中都存在购买记录:

$$\begin{aligned} R_u &= R_u^{new} \\ F_u &= F_u^{old} + F_u^{new} \\ M_u &= M_u^{old} + M_u^{new} \end{aligned}$$

➤ 情况 2: 用户 u 只在历史数据中存在购买记录, 没有在新增数据中存在购买记录:

$$\begin{aligned} R_u &= R_u^{old} + I \\ F_u &= F_u^{old} \\ M_u &= M_u^{old} \end{aligned}$$

其中 I 表示新增数据的时间间隔。假设我们每个月对 RFM 模型进行更新, 则 $I=30$ 。

➤ 情况 3: 用户 u 只在新增数据存在购买记录, 没有的历史数据中存在购买记录:

$$\begin{aligned} R_u &= R_u^{new} \\ F_u &= F_u^{new} \\ M_u &= M_u^{new} \end{aligned}$$

每个用户的 RFM 指标更新完成后, 还需要计算各个指标的平均值, 才能为用户分类。假设历史数据中的用户集合记作 U^{old} , 共包含 N^{old} 个用户, 且历史数据的 RFM 平均值分别为 R_{avg}^{old} 、 F_{avg}^{old} 、 M_{avg}^{old} 。假设新增数据中的用户集合记作 U^{new} , 共包含 N^{new} 个用户, 其中 N_1^{new} 个用户在历史数据中存在购买行为, 其中 N_2^{new} 个用户没有历史数据中存在购买行为, 则它们满足 $N_1^{new} + N_2^{new} = N^{new}$ 。更新后的 RFM 模型各个指标平均值可通过如下公式计算:

$$\begin{aligned} F_{avg} &= (F_{avg}^{old} \times N^{old} + \sum_{j \in U^{new}} F_j^{new}) / (N^{old} + N_2^{new}) \\ M_{avg} &= (M_{avg}^{old} \times N^{old} + \sum_{j \in U^{new}} M_j^{new}) / (N^{old} + N_2^{new}) \\ R_{avg} &= (\sum_{i \in U^j} (R_i^{old} + 30) + \sum_{j=1}^{N^{new}} R_j^{new}) / (N^{old} + N_2^{new}) \end{aligned}$$

其中 $U = U^{old} - (U^{old} \cap U^{new})$ 表示只在历史数据中存在购买记录的用户集合。

4.1.3 例子

假设基于历史数据统计的 RFM 数据如下:

表 2 基于历史数据统计的用户 RFM 表

用户	近度 R	频度 F	额度 M
$u1$	33	3	28
$u2$	34	1	27
$u3$	36	3	26
$u4$	37	1	59

可以计算每个指标的平均值:

$$r_{avg} = \frac{1}{4}(33 + 34 + 36 + 37) = 35$$

$$f_{avg} = \frac{1}{4}(3 + 1 + 3 + 1) = 2$$

$$m_{avg} = \frac{1}{4}(28 + 27 + 26 + 59) = 35$$

然后根据各用户 RFM 数据与平均值的大小关系计算每个用户在三个指标的打分情况, 以 $u1$ 为例:

$$r_1 = 33 < r_{avg} = 35 \Rightarrow sr_1 = 0$$

$$f_1 = 3 > f_{avg} = 2 \Rightarrow sf_1 = 1$$

$$m_1 = 28 > m_{avg} = 35 \Rightarrow sm_1 = 0$$

类似地, 可以得到全部用户的评分矩阵, 如表 3 所示:

表 3 基于历史数据统计的用户 RFM 打分表

用户	近度 R	频度 F	额度 M
$u1$	0	1	0
$u2$	0	0	0
$u3$	1	0	0
$u4$	1	1	1

根据表 1 可以得知四名用户的用户分类结果如表 4 所示:

表 4 基于历史数据统计的用户 RFM 用户划分表

用户	用户分类
$u1$	一般保持用户
$u2$	一般挽留用户
$u3$	一般发展用户
$u4$	重要价值用户

假设在表 2 的基础上, 又过了一个月, 增加了一个月的数据量, 并且这一个月 RFM 统计情况如下:

表 5 最新一个月的用户 RFM 表

用户	近度 R	频度 F	额度 M
----	--------	--------	--------

<i>u1</i>	10	2	18
<i>u3</i>	2	1	15
<i>u5</i>	5	2	18

其中增加了一个新的用户 *u5*，在之前表 1 中没有出现过。另外 *u2* 和 *u4* 由于没有在这一个月內买过商品，所以在表中没有记录。

根据表 2 和表 5，可以计算得到 $N^{old} = 4$, $N_2^{new} = 1$, $F_{avg}^{old} = 2$, $M_{avg}^{old} = 35$, $\dot{U} = \{u2, u4\}$ 所以根据小节 2.2 的公式可以得到：

$$F_{avg}^{new} = \frac{2 * 4 + 2 + 1 + 2}{4 + 1} = 2.6$$

$$M_{avg}^{new} = \frac{35 * 4 + 18 + 15 + 18}{4 + 1} = 38.2$$

$$R_{avg}^{new} = \frac{(34 + 30 + 37 + 30 + 10 + 2 + 5)}{4 + 1} = 29.6$$

可以看到利用增量式的方式不需要遍历历史数据去获得历史 RFM 值，节约了大量计算。

4.2 TGI 模型

TGI (Target Group Index) 又称目标群体指数，可反映目标群体在特定研究范围内的强势或弱势。简言之，就是比之全体成员，目标群体对某一物体或特征的偏好。TGI 指数可由如下公式计算得到：

$$TGI = \frac{\text{目标群体中某种特征所占比例}}{\text{总体中具有相同特征的群体所占比例}} \times 100\%$$

TGI 指数表征不同群体对相同问题的差异情况，其中 TGI 指数等于 100 表示平均水平，高于 100，代表该类用户对某类问题的关注程度高于整体水平。例如，假设在抽烟的人数在中国总人数的 35%，但是抽烟的男性占整体男性的 50%，那么 $TGI = 50/35 * 100\% = 142\%$ ，说明男性群体更喜欢抽烟。

基于第二节 RFM 模型的分类结果，本小节将利用 TGI 模型分析不同类别的客户对各种卷烟品牌的偏好程度，分析的大致流程如图所示。




图 3 TGI 分析流程

我们首先会利用 RFM 模型对客户进行分类（红色箭头部分），然后从历史数据中挑选销量最高的 4 种卷烟进行分析，统计 8 类用户对它们的 TGI 指数（蓝色箭头部分）。通过 TGI 指数，可以分析不同类型客户的卷烟偏好，为之后零售终端补货提供借鉴。

4.3 三种机器学习预测模型

本文采取了三种机器学习方法细粒度地预测了下次购买的商品类型，方法包括支持向量

机 (Support Vector Machine, SVM) , 随机森林 (Random Forest, RF) 、决策树 (Decision Tree, DT) 。

首先, 本文以用户前 5 次购买的卷烟品牌作为时序特征, 记作 X1、X2、X3、X4、X5, 并结合他历史上购买最频繁的卷烟品牌作为额外特征, 记作 Freq, 作为机器学习模型的输入参数。因为卷烟品牌众多, 所以预测任务实际上属于多分类问题。因此最终的模型输出 $\hat{y}$ 是一个多维的向量, 向量中的每一维对应的数字代表用户购买对应卷烟的概率。我们可以将概率最大的那一维代表的卷烟品牌作为最终的预测结果。我们这么确定参数经过了有无最频繁购买卷烟特征和有无不同 k 次消费记录的对比实验, 结果将展示在第五部分中。另外, 经过仔细的网格搜索, 根据预测结果我们确定了效率最高的模型参数。

5. 结果展示

5.1 RFM 模型

5.1.1 传统 RFM 模型运行截图

使用 pandas 实现了 RFM 模型, 运行时间仅为:

```
Running time: 1.123374752999979 Seconds
```

运行结果为:




图 4 RFM 用户分类情况

Type_x 中的 x 值为 RFM 值的十进制表示, 如 RFM 值为 1, 1, 1 的用户类型就是 Type7 类也即重要价值用户。

可以看出 Type1, 3, 5, 7 的用户是比较少的, 他们都是重要型用户, 符合我们筛选出少量

重要客户的标准。

5.1.2 增量式 RFM 模型的效率提升对比




图 5 增量式 RFM 模型与传统模型程序运行时间对比

可以看出数据优化程度效果比较显著，符合预期。同时也可以看出，当新增数据比例增多时，算法优化比例较小，故此模型适用于新增数据较小的情况。

5.2 TGI 模型

据统计，历史销量最高的四种卷烟从高到低排序分别是黄鹤楼（软蓝），利群（新版），黄鹤楼（硬奇景），红金龙（软精品）。图 10 展示了 8 种类别的客户分别对它们的 TGI 指数。

以黄鹤楼（软蓝）为例，重要价值用户对其的 TGI 指数为 929.925，远远高于 100 这一衡量标准，这说明重要价值用户相较其他用户对黄鹤楼（软蓝）的偏好程度是很高的；而重要挽留用户对其的 TGI 指数仅为 48.125，远远低于 100，从比例上来说，鲜少有重要挽留用户购买黄鹤楼（软蓝）。

若将四种销量最高的产品进行横向比较，不难发现这四种产品都较受一般保持用户、重要保持用户、一般价值用户、重要价值用户这四类用户的喜爱，且重要保持用户和重要价值用户尤为喜爱，而黄鹤楼（硬奇景）和红金龙（软精品）还受重要发展用户的喜爱。相比之下，重要价值用户最偏好利群（新版），重要保持用户和重要发展用户最偏好红金龙（软精品），重要挽留用户则最偏好黄鹤楼（硬奇景）。




图 6 不同类别客户对 TOP-4 卷烟的 TGI 指数图

5.3 三种机器学习预测模型

5.3.1 最频繁购买卷烟特征对预测效果的影响

在模型特征中，最近 5 次的消费记录均属于同类数据特征，所以又在此基础上增加了最频繁购买卷烟特征 (tzlabel)，并通过对比有无此特征时的模型预测准确率。




图 7 有无 tzlabel 特征效果对比图

图 13 中黑色条形代表准确率的平均值，灰色条形代表准确率的标准差。左边是有 tzlabel 时的结果，右边是没有该特征时的结果，从图中可以看出特征中有 tzlabel 时准确率达到了 59.32%，比没有 tzlabel 时提高了 7.62% 的准确率，体现了明显的效果。另外，标准差减小了 3.4%，使得模型的预测效果更准确，并且更加稳定。

5.3.2 前 k 次购买记录对预测效果的影响

本小节比较了不同 k 的取值，即考虑用户最近不同次数的购买行为对预测效果的影响。




图 8 不同 k 次消费记录的准确率均值比较图

图 14 对比了 5 个不同 k 次消费记录的准确率均值，从图中可以看出，随着 k 取值的增加，预测的准确率呈现先降低后升高的趋势。当 k=5 时的模型准确率相较于 k 为 2、3 和 4 时的准确率均值要高 0.92% 以上，而只以最近的购买记录作为特征的模型预测准最高，说

明用户的购买行为与他最近的一次购买行为最相关，同时也与他长期的行为有关。




图 9 不同 k 次消费记录的准确率标准差比较图

图 15 比较了五个不同 k 值的准确值标准差，可以看出，在后四个 k 值中，5 次消费记录的标准差是最小的，达到了 9.32%，说明 k=5 时的预测效果最好，最稳定。同样 k=1 时虽然标准差比较小，但是客户在消费时，一次记录的随机性比较大，并不能说明客户的长期消费偏好和消费习惯，所以综合考虑各个 k 值的预测效果和意义，最终选取了 k=5 作为实验特征。

5.3.2 三种机器学习模型预测准确率与标准差




图 10 三种机器学习模型预测准确率与标准差

从运行结果可以看出准确率最高的算法是决策树，准确率为 0.6008。最稳定的算法是随机森林，标准差仅为 0.088。从准确度来说模型还不够完美，后续可以考虑尝试使用神经网络种的 LSTM 模型继续优化。

6.项目特色

- 1.数据集来源于生活，解决了真实存在的问题。湖北烟草局对我们我们小组提供的方案较满意，并希望我们继续对数据和模型进行挖掘、完善。
- 2.数据量巨大，数据之间关系复杂。
- 3.改进了传统的 RFM 模型，实现了更快的更新。
- 4.全面的使用了 np, pandas, 正则, matplotlib, 机器学习, pandas 读取数据库等技巧。
- 5.机器学习进行了网格化搜索与参数对比，实现了对用户下次购买烟草品种的细粒度预测。

7.任务分工

徐声远: RFM 模型, 增量式 RFM 模型, 机器学习

叶飞: 数据清洗整理, 文档撰写

杨铁皓: TGI 模型, PPT 制作

我们每一周三周六都会开会直至项目结束，还与湖北烟草局进行了数次会议交流。项目任务与进度都在飞书的任务看板中布置与同步。



8 总结

本文利用零售终端收集的消费者历史购买记录,从三个方面提出了一套完整的烟草客户画像构建方法。首先设计了一种增量式 RFM 模型对客户进行价值分类,判断客户是否属于重要价值客户,是否需要重点挽留等。然后利用 TGI 模型对分类好的客户进行卷烟偏好分析,粗粒度地分析各个类别客户的更喜欢购买的卷烟品牌。虽然在本文中我们只分析了销量前四的卷烟品牌,但是可以轻松地扩展到其他卷烟品牌中。最后,使用三种机器学习模型,细粒度地预测每个客户在未来可能购买的卷烟品牌。我们以客户最近 5 次购买记录以及历史上最频繁购买的卷烟品牌作为输入特征。通过真实卷烟购买数据做实验,验证了该模型能

够实现最好的预测准确率, 达到了 60.08%。

在之后的工作中, 我们将继续优化卷烟预测模型, 希望能够挖掘消费者兴趣变迁的模式, 提高模型预测准确度。另外, 我们也将开展对非烟商品的研究。

致 谢 *致谢内容:* 致谢

参 考 文 献

- [1]. 聂晓洁. A公司卷烟销售预测与库存控制策略研究[D].山东财经大学,2021.
- [2]. 张瀚月. 新零售背景下S市烟草公司卷烟零售终端管理策略研究[D].河南大学,2020.
- [3]. Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.
- [4]. Park J H, Kim Y S, Eom I K, et al. Economic load dispatch for piecewise quadratic cost function using Hopfield neural network[J]. IEEE transactions on power systems, 1993, 8(3): 1030-1038.
- [5]. Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[J]. arXiv preprint arXiv:1301.3781, 2013.
- [6]. Martinez M, Stiefelhagen R. Taming the cross entropy loss[C]//German Conference on Pattern Recognition. Springer, Cham, 2018: 628-637.
- [7]. Kingma D P, Ba J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.
- [8]. 叶志龙,黄章树.基于新三维客户细分模型的线上会员客户价值研究[J].统计与信息论坛,2016,31(05):96-101.
- [9]. 冯喆,侯霄昱,郭子欣.基于改进型RFM卷烟消费者价值细分模型的精准营销策略研究[J].经济师,2019(12):279-281.
- [10]. Anitha P, Patil M M. RFM model for customer purchase behavior using K-Means algorithm[J]. Journal of King Saud University-Computer and Information Sciences, 2019.
- [11]. Khajvand M, Zolfaghar K, Ashoori S, et al. Estimating customer lifetime value based on RFM analysis of customer purchase behavior: Case study[J]. Procedia Computer Science, 2011, 3: 57-63.
- [12]. You Z, Si Y W, Zhang D, et al. A decision-making framework for precision marketing[J]. Expert Systems with Applications, 2015, 42(7): 3357-3367.
- [13]. 邓基刚,郑成德,刘景燕,黄胜茂,王无瑕.基于RFM模型的卷烟品牌聚类细分研究[J].中小企业管理与科技(中旬刊),2015(01):8-9.
- [14]. 余晓晓. 基于改进LSTM-SVR的预测模型及其在烟草行业的应用研究[D].华中科技大学,2020.
- [15]. 洪峰,潘法昱,赵建翊,高楠,曹斌,范菁.一种面向烟草行业的供给预测服务算法[J].小型微型计算机系统,2019,40(08):1640-1645.
- [16]. 刘璐,丁福利,孙立民.基于SVM的烟草销售量预测[J].软件导刊,2016,15(11):134-137.
- [17]. 沈秋云. 卷烟商业销量预测方法的研究[D].上海交通大学,2018.
- [18]. 王红影,马成文. 基于ARMA模型的中国烟草产量预测[J]. 齐齐哈尔工程学院学报,2016(3).

- [19]. 仲东亭,张玥.BP神经网络对烟草销售量预测方法的改进研究[J].工业技术经济,2007(09):115-118.
- [20]. Sakdiah S H, Eltivia N, Riawanti N I, et al. Forecasting Analysis on the Impact of Pandemic Towards Cigarette Sales[C]//2nd Annual Management, Business and Economic Conference (AMBEC 2020). Atlantis Press, 2021: 263-268.
- [21]. Fang D, Weng W. Sales forecasting system for chinese tobacco wholesalers[J]. Procedia Environmental Sciences, 2011, 11: 380-386.