

自然光光谱预测 与室内照明补偿设计

使用 Python 数据处理、PCA 降维与机器学习模型，估计自然光相对光谱

第24组 Python 应用开发基础课程设计
李安逸、黄奕滔

随机森林

机器学习

5664

样本量

98.3%

PCA 累计方差

照明不只有亮度和色温维度

亮度

照度看“够不够亮”

色温

看冷暖，但不够细致


光谱

各波长能量分布

现代人越来越多时间处在室内，人工照明对学习、办公和生活体验都有影响。常见照明调节主要关注亮度和色温，但这两个指标不能完全描述光的组成。光谱能表示不同波长上的能量分布，是更细致的光照描述方式。

基于光谱的室内照明调节，是未来高质量照明的一个潜在方向。

Ra 是传统显色评价指标，主要衡量 8 个低饱和标准色样的平均色差，因此对高饱和颜色、红色表现、肤色质感和光谱缺陷不敏感，不能作为光照质量的完整指标。



不同天气下平均相对光谱存在差异

光谱如何获取

专业光谱仪难以在普通场景普及，因此尝试用更容易获得的环境特征，比如天气预报数据，通过机器学习估计自然光相对光谱。



目标：输入低成本环境特征，输出自然光相对光谱，并进一步用于照明补偿。

基于公开观测数据训练

SKYSPECTRA 实测天光光谱

Zenodo record 8147546

水平天光光谱 + 元数据

重采样到 380–780 nm / 10 nm

Open-Meteo 历史天气 API

按观测站经纬度和日期查询

云量、湿度、温度、降水

按最近整点与光谱对齐

公开 LED 光谱数据

用于七通道 LED 补偿模型

深蓝、青、绿、琥珀、红、暖白、冷白

只用于补偿，不参与训练

处理流程



5664

样本量

41

光谱维度

2016–2018

时间范围

2

观测站

法国沃昂夫兰

主要站点

模型输入：低成本环境特征

输入特征 (12 个)

数值特征 (9 个)


- 🕒 hour, month
- ☀️ solar_altitude, solar_azimuth
- ☁️ cloud_cover, humidity, temperature
- 🌧️ precipitation, outdoor_lux

类别特征 (3 个, 独热编码)

- 🌤️ weather (天气类别)
- 🌤️ sky_condition (天空状况)
- 📍 location_code (观测站编号)


数值特征标准化 + 类别特征独热编码

随机森林特征重要性



outdoor_lux 54% · cloud_cover 9% · solar_azimuth 6%

输出：41 维相对光谱



光谱曲线示例：380–780 nm 范围内的相对光谱

输出目标

380–780 nm 可见光范围每 10 nm 一个点，共 41 维
关注相对光谱形状

基于真实天光数据的自然光光谱估计与室内照明补偿设计

	wavelength_400	wavelength_410	wavelength_420	wavelength_430	wavelength_440	wavelength_450
	0.0636	0.0636	0.0636	0.0506	0.0663	0.0636
	0.064	0.064	0.064	0.0526	0.0697	0.0636
	0.0671	0.0671	0.0671	0.0545	0.0733	0.0636
	0.0698	0.0698	0.0698	0.0587	0.0766	0.0636
	0.0734	0.0734	0.0734	0.0606	0.0796	0.0636
	0.0741	0.0741	0.0741	0.0635	0.0831	0.1018
0	wavelength_620	wavelength_630	wavelength_640	wavelength_650	wavelength_660	wavelength_670
9	0.061	0.0568	0.0605	0.057	0.0598	0.0636
5	0.0649	0.061	0.0642	0.061	0.0634	0.0636
3	0.0693	0.0648	0.0688	0.0654	0.0676	0.0636
1	0.0729	0.0684	0.0723	0.0686	0.0714	0.0636
4	0.0766	0.0715	0.0758	0.0725	0.0748	0.0636
2	0.0803	0.0755	0.0797	0.0762	0.0784	0.0636



为什么需要 PCA

光谱曲线连续变化，相邻波长值高度相关 → 适合 PCA 压缩
直接预测 41 维会增加模型难度

每条光谱除以自身最大值，模型学习光谱形状而非绝对强度

为什么选择 5 个主成分

测试前 1 ~ 10 个主成分的累计解释方差，选择能保留大部分信息的最少数目。



前 5 个主成分累计解释方差已经达 98.35%，足以保留绝大部分光谱信息！

PCA 降维流程



为什么要这样做

原始光谱 41 维，相邻波长强相关，直接预测维度高、难度大。PCA 把主要变化压缩成 5 个系数，既保留形状信息（98.3%），也便于回归模型学习。

关键数字

5
主成分数量

98.3%
累计解释方差

PCA 不是为了让结果更"高级"，而是为了让模型更容易学习。

尝试多种模型，用结果选择方案

把光谱估计作为回归问题，尝试课程中涉及的多种模型路线

Linear Regression

线性基准模型

观察问题是否接近线性关系
最简单的回归模型

误差明显较大

KNN

K 近邻回归

基于邻域的非参数模型
MAE 略低但 RMSE 不占优

Decision Tree

决策树回归

单棵决策树，中间对比
稳定性不如集成模型

Random Forest

随机森林回归

集成学习模型
关注稳定性和非线性拟合

最终选择



MLP

神经网络回归




更复杂的非线性模型
 R^2 略高但 RMSE 更大

所有模型使用相同的数据划分、相同输入特征和相同 PCA 输出目标，最后用统一指标比较效果。

评价维度：MAE / RMSE / R^2 / 训练时间 / 推理时间

五个模型在同一数据上评价

模型	MAE	RMSE	R ²	训练/s	预测/s
Random Forest	0.0051	0.0086	0.959	0.94	0.12
KNN	0.0050	0.0090	0.954	0.03	0.14
MLP	0.0058	0.0095	0.962	1.87	0.22
Decision Tree	0.0054	0.0124	0.870	0.03	0.01
Linear Regression	0.0225	0.0376	0.635	0.03	0.01



随机森林 RMSE 最低 (0.0086) , 综合稳定性最好 → 最终选择

选择 Random Forest: 效果与成本更平衡

线性回归作为基线

误差明显较大 ($RMSE=0.0376$) , 说明数据不是简单线性关系

为什么关注 MLP

代表神经网络路线, R^2 略高但训练、预测计算量更大

为什么最终选择 Random Forest

$RMSE$ 最低、推理成本低、集成模型稳定性好

选择依据

不只看 R^2 , 也结合 $RMSE$ 、成本和预测稳定性

RF vs MLP

Random Forest

$RMSE$: 0.0086 · R^2 : 0.959 · 训练: 0.94s

$RMSE$ 最低, 综合最优 ✓

MLP

$RMSE$: 0.0095 · R^2 : 0.962 · 训练: 1.87s

R^2 略高但 $RMSE$ 更大、训练更慢

结论

以实验结果为依据, 不预先认定某个模型最好。

综合 $RMSE$ 、稳定性和推理成本选择。

随机森林参数设置与调优

关键参数

`n_estimators = 100` 决策树数量，越多越稳定但训练越慢

`max_depth = 20` 树的最大深度，控制模型复杂度

`min_samples_split = 5` 内部节点再分裂所需最小样本数

`random_state = 42` 随机种子

代码示例

```
for name, model in build_models(random_state=random_state).items():  
    result = train_single_model(name, model,  
                                x_train, y_train_pca, x_test, spectrum_pca)  
.....
```

调优过程

1. 参数对比实验

固定其他参数，逐一测试各参数的影响

2. 交叉验证

使用 K 折交叉验证评估参数组合稳定性

3. 选择最优组合

综合 RMSE 和训练时间选择最佳参数


4. 最终模型

使用调优后的参数训练最终模型

```
grid = GridSearchCV(rf, param_grid, cv=5)  
grid.fit(X_train, y_train)  
best_rf = grid.best_estimator_
```


预测结果与照明补偿

光谱预测结果



蓝色=实测，红色虚线=预测，两条曲线基本重合

七通道 LED 补偿



多通道 LED 自由度更多，能按波段局部补偿

预测路径：环境特征 → 5 个 PCA 系数 → PCA 逆变换 → 41 维光谱 → LED 补偿



特色与不足

特色

1. 使用真实公开天光光谱数据
2. 覆盖数据处理、PCA、ML、可视化与应用全流程
3. 输入易获取，模型成分精简，效率高，效果出色
4. 多模型统一比较，按结果选择模型
5. 预测光谱用于照明补偿，形成应用闭环

主要不足

1. 样本集中在少数站点
数据来源有限，特别是缺少国内数据，代表性不够广泛
2. 天气数据与光谱非完全同步
天气为对齐的历史特征，非现场测量
3. 模型不能完全替代专业光谱仪
估计的是相对光谱形状，非绝对测量，不能代替专业场景
4. 当前是算法演示，未接入硬件
暂未接入真实照明硬件验证
5. 补偿效果有待更细的评价
可进一步评估舒适度和显色效果，以及个性化后处理

小组分工与大模型使用

小组分工

李安逸

负责数据收集与处理、数据调整、可视化调整、课程报告撰写与编写。

黄奕滔

负责数据处理、代码实现、可视化实现、课程报告检查和补充。

共同完成

主题讨论、文献查阅、幻灯片制作、答辩准备、结果检查和最终材料整理。

课程名称：Python 应用开发基础
第24组

大模型使用情况

使用大模型辅助的环节：

数据源收集和汇总

报告结构整理和辅助编写

代码注释与编写辅助

可视化表达相关代码编写辅助